

Analiza zbioru danych "Patient-level dataset to study the effect of COVID-19 in people with Multiple Sclerosis" z wykorzystaniem nadzorowanego algorytmu uczenia maszynowego One-Class SVM(Support Vector Machines)

Anna Mrozek, Bartosz Panek i Przemysław Jura

ARTICLE INFO

Keywords:
One-Class SVM
COVID-19

STRESZCZENIE

Artykuł analizuje zbiór danych pacjentów ze stwardnieniem rozsianym (SM), którzy przeszli COVID-19, przy użyciu nadzorowanego algorytmu One-Class SVM. Celem jest identyfikacja przypadków o zwiększonym ryzyku ciężkiego przebiegu infekcji. Umożliwi to zidentyfikowanie charakterystycznych cech pacjentów bardziej narażonych na powikłania.

1. Wprowadzenie

Pandemia COVID-19 miała znaczący wpływ na osoby z chorobami przewlekłymi, w tym na pacjentów ze stwardnieniem rozsianym (SM). SM jest przewlekłą chorobą autoimmunologiczną, która wpływa na układ nerwowy i może prowadzić do trwałego uszkodzenia neuronów oraz ograniczenia funkcji motorycznych oraz poznawczych przez uszkodzenia mieliny oraz włókien nerwowych [1][2][3]. Osoby z MS są bardziej podatne na infekcje z powodu złożonego działania samej choroby, jej leczenia i naturalnego przebiegu [4]. Ze względu na charakter choroby i stosowane terapie immunosupresyjne, pacjenci z SM mogą być bardziej narażeni na cięższy przebieg infekcji wirusowych, w tym COVID-19.[5][6]

Analiza danych od pacjentów z SM, którzy przeszli COVID-19, może dostarczyć ważnych informacji na temat ryzyka powikłań i zidentyfikować czynniki przyczyniające się do poważniejszych objawów, co ostatecznie może pomóc w lepszym monitorowaniu i opiece nad tą grupą pacjentów.

2. Cel

Celem badania jest wykorzystanie nadzorowanego algorytmu One-Class SVM do analizy zbioru danych pacjentów ze stwardnieniem rozsianym, którzy przeszli COVID-19, w celu zidentyfikowania cech pacjentów o zwiększonym ryzyku ciężkiej infekcji. Oczekuje się, że wyniki analizy dostarczą wskazówek do opracowania bardziej ukierunkowanych strategii opieki i środków zapobiegawczych dla pacjentów ze stwardnieniem rozsianym w kontekście potencjalnych przyszłych pandemii lub innych zagrożeń wirusowych.

3. Przegląd literatury

W literaturze medycznej i naukowej, od początku pandemii COVID-19, wiele badań skupiało się na analizie wpływu wirusa SARS-CoV-2 na osoby cierpiące na choroby

przewlekłe i autoimmunologiczne, takie jak stwardnienie rozsiane (SM). Wyniki tych badań sugerują, że pacjenci z SM, zwłaszcza ci stosujący terapie immunosupresyjne, mogą być bardziej narażeni na cięższy przebieg COVID-19 oraz związane z nim powikłania[7][8]. U pacjentów z SM często obserwuje się obniżoną odporność oraz większą podatność na infekcje, co wynika zarówno z samej choroby, jak i z efektów leków tłumiących układ odpornościowy[9]. Dodatkowo w badaniach zwraca się uwagę na takie czynniki ryzyka jak wiek, płeć, rodzaj stosowanego leczenia oraz inne choroby towarzyszące, które mogą zwiększać ryzyko ciężkiego przebiegu infekcji u tej grupy pacjentów.

W ostatnich latach coraz większą popularność zyskuje zastosowanie algorytmów uczenia maszynowego, takich jak Support Vector Machines (SVM), do analizy danych medycznych. Algorytmy te pozwalają na wykrywanie wzorców i anomalii w dużych, zróżnicowanych zbiorach danych[10]. W szczególności algorytm One-Class SVM, używany do wykrywania anomalii, jest przydatny do identyfikacji przypadków wysokiego ryzyka w danych medycznych, gdzie przypadki nietypowe (np. pacjenci bardziej narażeni na ciężki przebieg COVID-19) występują rzadko. Badania pokazują, że One-Class SVM dobrze sprawdza się w analizie populacji pacjentów, gdy dostęp do dużych zbiorów danych o przypadkach zdrowych jest ograniczony, co często stanowi wyzwanie w analizie medycznej[11].

W kontekście badań nad COVID-19 i SM, algorytmy nadzorowanego uczenia maszynowego, takie jak SVM, umożliwiają dokładniejszą analizę czynników ryzyka oraz lepsze prognozowanie ciężkiego przebiegu choroby. Wyniki takich analiz mogą być przydatne nie tylko dla lekarzy, ale także dla decydentów zajmujących się zdrowiem publicznym, ponieważ pozwalają na opracowanie bardziej ukierunkowanych strategii opieki dla osób z SM, które są bardziej narażone na zagrożenia związane z wirusami, takimi jak COVID-19.

4. Metodologia

W badaniu zastosowano algorytm nadzorowanego uczenia maszynowego One-Class SVM w celu identyfikacji pacjentów z podwyższonym ryzykiem ciężkiego przebiegu COVID-19 w grupie osób ze stwardnieniem rozsianym. Analiza obejmowała cechy kliniczne pacjentów, takie jak wiek, płeć, typ leczenia oraz choroby współistniejące, aby zidentyfikować wzorce związane z większą podatnością na powikłania.

4.1. Dataset

Z inicjatywy MS Global Data Sharing Initiative (GDSI) zbadano, jak leki immunosupresyjne lub immunomodulujące wpływają na COVID-19 i jego przebieg u osób z MS. GDSI miała na celu zwiększenie skali zbierania danych dotyczących COVID-19 i dostarczenie społeczności związanej z MS informacji opartych na danych podczas pandemii [12]. W ramach GDSI wybrano kluczowe zmienne obejmujące informacje o COVID-19, stopniu jego ciężkości, leczeniu, dane demograficzne, historię i nasilenie MS, stosowanie leków modyfikujących przebieg choroby (DMT), choroby współistniejące i wybrane zachowania związane ze stylem życia, takie jak palenie tytoniu. Globalna społeczność MS współpracowała, przekazując dokumentację statusu COVID-19 u osób z MS za pośrednictwem centralnej platformy udostępnionej przez QMENTA [13].

Ten zbiór danych został zebrany za pomocą narzędzia do szybkiego wprowadzania danych, które umożliwiło klinicystom, osobom ze stwardnieniem rozsianym (PwMS) lub ich przedstawicielom bezpośrednie wprowadzanie informacji do centralnej platformy GDSI. Narzędzie to zawierało kwestionariusz oparty na wcześniej ustalonych zmiennych i nie gromadziło bezpośrednich danych osobowych, aby chronić prywatność użytkowników. Narzędzie zostało wyłączone 3 lutego 2022 roku.

Zbiór danych obejmuje informacje o 1141 osobach ze stwardnieniem rozsianym (PwMS). Aby zapewnić zgodność danych z wytycznymi HIPAA, przeprowadzono proces deidentyfikacji.

Ponieważ w danych nie zbierano imion pacjentów, deidentyfikacja skupiała się na datach i wieku pacjentów. Daty w kolumnie „stop-or-end-date-combined” zostały przesunięte o losową liczbę dni (między -15 a 15), aby uniemożliwić identyfikację na podstawie dat. Wiek pacjentów sklasyfikowano w cztery grupy: 0 dla osób w wieku 0–17 lat, 1 dla osób między 18 a 50 lat, 2 dla osób między 51 a 70 lat, oraz 3 dla osób powyżej 71 lat. Dzięki temu żadne dokładne wartości wieku powyżej 90 lat nie zostały ujawnione. Po klasyfikacji zmiennych i wdrożeniu odpowiednich środków ostrożności dane zostały zdeidentyfikowane i spełniają standardy HIPAA, zachowując jednocześnie wartość badawczą. Ponadto, aby zapewnić ochronę prywatności, zastosowano techniki takie jak Kanonimizacja oraz różnorodność.

Zbiór danych obejmuje zestaw z góry określonych zmiennych, takich jak płeć, kategoria wiekowa, typ MS, wynik EDSS, status palenia oraz kategoria BMI. Te zmienne

dostarczają informacji o demografii pacjentów, ich stanie klinicznym oraz symptomach związanych z COVID-19.

4.2. Opis metody

Jednoklasowy SVM (One-Class Support Vector Machine, OCSVM) to algorytm przeznaczony do wykrywania anomalii w zbiorze danych. Zamiast klasyfikować dane do dwóch lub więcej klas, jak w klasycznym SVM, OCSVM koncentruje się wyłącznie na danych normalnych.[14][15] Jego celem jest zbudowanie granicy wokół większości przypadków normalnych, tworząc "strefę normalności", która odróżnia standardowe przypadki od anomalii.

Główna zasada działania OCSVM opiera się na maksymalizacji marginesu między przypadkami normalnymi a granicą, która oddziela normę od anomalii. Dzięki temu model lepiej rozpoznaje dane odstające, które znajdują się poza wyznaczoną strefą.[16][17]

Kluczowym elementem działania OCSVM jest funkcja decyzyjna oparta na hiperpłaszczyźnie, która oddziela dane od początku układu współrzędnych. Wzór na hiperpłaszczyznę wyrażany jest jako:

$$f(x) = \mathbf{w} \cdot \mathbf{x} - \rho \quad (1)$$

gdzie:

- \mathbf{w} – wektor normalny do hiperpłaszczyzny, wyznaczony podczas procesu uczenia,
- \mathbf{x} – próbka danych,
- ρ – jest wartością progową (bias), która definiuje margines.

OCSVM posiada szereg parametrów, dzięki którym możliwe jest dostosowywanie modelu do specyficznych potrzeb:

- **Parametr ν :** Kontroluje liczbę obserwacji uznawanych za anomalie. Parametr ten przyjmuje wartości w przedziale od 0 do 1 i determinuje udział anomalii, jakie model może tolerować w zbiorze treningowym (np. jeśli $\nu = 0.05$, oznacza to, że około 5% próbek zostanie sklasyfikowanych jako anomalie).
- **Parametr γ :** Wpływa na kształt granicy decyzyjnej poprzez dopasowywanie modelu do danych. Mniejsza wartość γ oznacza „szerszą” granicę, obejmującą więcej punktów, natomiast większa wartość γ powoduje, że granica jest bardziej dopasowana do danych, co może zwiększać ryzyko nadmiernego dopasowania (overfitting).
- **Jądro (*ang. kernel*):** One-Class SVM często wykorzystuje funkcje jądrowe, aby modelować nieliniowe granice decyzyjne i lepiej dopasować się do danych, które nie są liniowo rozdzielne w przestrzeni cech. Wybór jądra, zwany również „sztuczką jądra”, wpływa na charakter dopasowania modelu i jego wydajność.

Podczas treningu OCSVM analizuje wyłacznie dane normalne, co sprawia, że jest szczególnie użycyeczny w sytuacjach, gdy anomalie sę rzadkie lub trudne do zidentyfikowania. Model staje się wtedy bardziej niezawodny w rzeczywistych zastosowaniach, takich jak wykrywanie oszustw, monitorowanie awarii czy zabezpieczanie sieci komputerowych. OCSVM może wykorzystać różne funkcje jądra, co umożliwia mu wykrywanie zarówno prostych, jak i bardziej złożonych odchyleń.[18]

4.3. Opis przeprowadzonych obliczeń

1. Przygotowanie i czyszczenie danych - rozpoczęliśmy od wczytania danych oraz wybrania interesujących nas cech, które następnie zostały przekształcone w sposób umożliwiający przeprowadzenie obliczeń:

- Dla kolumn binarnych (yes/no) wartości zostały zamienione na liczby 0 i 1.
- Dla kolumn kategorycznych i ordinalnych (np. age-in-cat, covid19-outcome-levels-2, report-source) zostały przypisane wartości liczbowe, zgodnie z przyjętym mapowaniem.
- Brakujące wartości w danych zostały wypełnione zerami, co pozwoliło na uniknięcie problemów podczas analizy i treningu modelu.

2. Tworzenie nowych zmiennych: symptom-score oraz comorbidity-score, aby skonsolidować informacje o objawach i chorobach współistniejących.

- Stworzyliśmy dwie kolumny symptom-score oraz comorbidity-score, które zliczają ilość objawów wirusa COVID-19 oraz liczby chorōb współistniejących dla każdego pacjenta.
- Kolumny te były następnie skalowane przy użyciu StandardScaler, co pozwala na lepszą interpretację wyników oraz standaryzację w zakresie modelowania.

Efektom było, uzyskanie wartości numerycznych, które reprezentują intensywność symptomōw oraz liczbę chorōb współistniejących dla każdego pacjenta.

3. Dane zostały podzielone na zbiōr treningowy (X_train) i testowy (X_test) za pomocą funkcji train_test_split z biblioteki sklearn, przy czym 70% danych przydzielono do zbioru treningowego. Zbiōr treningowy służy do uczenia modelu, natomiast testowy do testowania zbioru dało to próbę około 350 pacjētōw. Ustawienie argumentu random_state=42 zapewnia reprodukowalność wyników, dzięki czemu podział danych jest zawsze taki sam przy kolejnych uruchomieniach. Warto zaznaczyć, iż na potrzeby dalszej oceny modelu pacjenci hospitalizowani zostali uznani za anomalie ponieważ najczęściej przeszli chorobę (ok. 2%). Dlatego do nauki modelu zostali wykorzystani jedynie pacjenci nie hospitalizowani, w celu nauczenia danych na danych normalnych. Natomiast w danych testowych znalazły się wszystkie przypadki anomalii, około 15 pacjētōw.

4. Trening modelu One-Class SVM - zastosowaliśmy algorytm One-Class Support Vector Machine (SVM) z jądrem rbf, który dobrze radzi sobie z modelowaniem nieliniowych granic decyzyjnych. Model trenowano, aby rozpoznawał typowe cechy pacjentōw COVID-19 i SM, a następnie by przewidywał, które próbki sę podobne do tego wzorca, a które mogą być anomaliami. Po treningu model przypisywał każdej próbce etykietę 1 (normalna) lub -1 (anomalina). Próbki oznaczone jako anomalina zawarto w nowej ramce anomalies w celu dalszej analizy. Model trenowano na różnych parametrach, czy to wielkości przyjętych anomalii, kształtu granicy decyzyjnej czy współczynnika jądra. Najlepsze wyniki osiągał dla przyjętych 2% anomalii i współczynnika jądra 'scale'.

5. Analiza wyników - na podstawie wykrytych anomalii przeprowadziliśmy szereg analiz, tworząc wizualizacje, które pomagają zrozumieć charakterystykę anomalii[19]

4.4. Wykorzystane metryki oceny

Raport klasyfikacji (ang. classification report) to podsumowanie wyników modelu klasyfikacyjnego, które przedstawia kluczowe metryki takie jak precyzja (precision), czułość (recall), i F1-score dla każdej klasy. Precyzja wskazuje, jak wiele z klasyfikacji pozytywnych jest poprawnych, podczas gdy czułość pokazuje, ile przykładōw rzeczywiście pozytywnych zostało poprawnie sklasyfikowanych. F1-score jest średnią harmoniczną precyzji i czułości, co sprawia, że dobrze nadaje się do oceny modeli na danych niebalansowanych. Raport zawiera również wskaźnik wsparcia (support), który pokazuje liczbę przykładōw w każdej klasie.

Dokładność, inaczej zwana accuracy, to stosunek liczby poprawnych predykcji (zarówno pozytywnych, jak i negatywnych) do całkowitej liczby przykładōw w danych testowych. Jest to ogólny wskaźnik skuteczności modelu. Jednak w przypadku danych niebalansowanych, dokładność może być myląca, ponieważ wysoka wartość może wynikać z dominacji jednej klasy. Dlatego warto uzupełniać analizę dokładności bardziej szczegółowymi metrykami, jak np. F1-score czy False Positive Rate.

Funkcja decyzyjna (ang. decision_function) w modelach takich jak One-Class SVM określa odległość przykładōw od granicy decyzyjnej modelu. Wyniki funkcji decyzyjnej wskazują, na ile pewnie model klasyfikuje przykład jako normalny lub anomalie. Wartości dodatnie sugerują, że przykład jest wewnątrz granicy klasy normalnej, a wartości ujemne sugerują, że przykład jest anomalie. Wartości bliżej zera oznaczają, że przykład znajduje się blisko granicy decyzyjnej.

Odsetek anomalii określa, jaka część danych została sklasyfikowana jako anomalie przez model. W modelach takich jak One-Class SVM parametr nu kontroluje, jaki procent danych jest uważany za anomalie podczas trenowania modelu. Jeśli odsetek anomalii w wynikach jest znacznie wyższy niż zakładany, może to oznaczać nadmierną surowość modelu. Z kolei zbyt niski odsetek może sugerować, że model nie wykrywa rzeczywistych anomalii.

False Positive Rate (FPR) to wskaźnik fałszywych alarmów, obliczany jako stosunek liczby fałszywie pozytywnych klasyfikacji (FP) do liczby wszystkich rzeczywistych przykładów negatywnych (FP + TN). Wysoki FPR oznacza, że model często błędnie klasyfikuje normalne przypadki jako anomalie, co może być problematyczne w zastosowaniach wymagających dużej precyzji (np. w diagnostyce medycznej). Zmniejszenie FPR można osiągnąć przez odpowiednie dostrojenie parametrów modelu lub zmianę progu decyzyjnego.

5. Wyniki

5.1. Ocena modelu One-Class SVM

	precision	recall	f1-score	support
0	0.44	0.53	0.48	15
1	0.98	0.97	0.97	338
accuracy			0.95	353
macro avg	0.71	0.75	0.73	353
weighted avg	0.96	0.95	0.95	353

Dokładność: 95.18%
Funkcja decyzyjna (Średni score): 0.101
Dokładność dla założonych anomalii: 8/15
Odsetek anomalii: 5.10%
False Positive Rate (FPR): 0.47

Figure 1: Ocena modelu One-class SVM




Figure 2: Rozkład wartości decyzji dla danych modelu One-class SVM

Na potrzeby oceny modelu, zostały wyodrębnione potencjalne dane które prawdopodobnie były anomaliami to znaczy przypadkami, które wymagały hospitalizacji i poważniejszego leczenia. To właśnie ta grupa osób została uznana za tą którą najczęściej przeszła chorobę. Za potencjalne anomalie zostały uznane przypadki, które

w danych w kolumnie covid19_admission_hospital zawierały informacje o hospitalizacji. Dodatkowo fakt, iż jedynie ok 2% osób badanych trafiło do szpitala potwierdzało założenie, że to właśnie tam należy doszukiwać się potencjalnych anomalii.

Model klasyfikacyjny został oceniony na podstawie kilku metryk, takich jak precyzja (precision), czułość (recall), F1-score, oraz wsparcie (support). Dla klasy 0 (anomalii) precyzja wyniosła 0.44, co oznacza, że jedynie 44% przypadków sklasyfikowanych jako anomalie było poprawnych. Czułość wyniosła 0.53, co wskazuje, że model wykrył 53% rzeczywistych anomalii. Niski F1-score (0.48) podkreśla trudności modelu w skutecznym identyfikowaniu anomalii, co jest szczególnie problematyczne przy tylko 15 przykładach rzeczywistych anomalii (support). Dla klasy 1 (normalny przypadek), wyniki są bardzo wysokie – precyzja 0.98 i czułość 0.97 świadczą o dużej skuteczności modelu w identyfikacji normalnych przypadków, co znajduje odzwierciedlenie w wysokim F1-score równym 0.97. Średnia dokładność modelu (accuracy) wyniosła 95.18%, co sugeruje ogólną skuteczność klasyfikacji, ale maskuje problem niskiej wydajności w detekcji anomalii.

Odsetek anomalii w zbiorze danych wynosi 5.10%, co wskazuje na dużą nierównowagę klas. False Positive Rate (FPR) na poziomie 0.47 oznacza, że model często błędnie klasyfikuje normalne przypadki jako anomalie. Dodatkowo, średni wynik na danych testowych z funkcji decyzyjnej wyniósł 0.101, co wskazuje, że większość przykładów testowych znajduje się blisko granicy decyzyjnej modelu. To może sugerować, że model ma trudności z wyraźnym rozdzieleniem klas, szczególnie w przypadku anomalii.

5.2. Wynik analizy

Wykresy znajdują się na końcu opracowania.

6. Opis wyników

Opis wykresów znajdujących się na końcu opracowania:

Figure 3: Na wykresie widzimy histogram z liczbą próbek oznaczonych jako normalne i anomalie przez model One-Class SVM. Z wykresu wynika, że większość próbek została sklasyfikowana jako normalne (oznaczone jako 1), podczas gdy mniejsza liczba próbek została uznana za anomalie. Wysoka liczba normalnych próbek w stosunku do anomalii wskazuje, że model wykrywa anomalie rzadziej, co jest zgodne z celem detekcji anomalii, ponieważ anomalie rzadziej występują.

Figure 4: Histogram pokazuje, że większość przypadków anomalii ma niski symptom_score, głównie na poziomie 0, z kilkoma przypadkami rozproszonymi na wyższych wartościach aż do 10. Niskie wartości mogą sugerować, że większość anomalii wykazuje niewiele lub żadnych symptomów, choć istnieją wyjątki, gdzie symptom score jest wyższy.

Figure 5: Histogram przedstawia, że większość anomalii ma comorbidity_score równy zero, co oznacza brak

chorōb wspōlistniejających, chociaŹ kilka przypadkōw posiada wyŹsze wartoŹci aŹ do 5. To sugeruje, Źe choć wiele przypadkōw anomalii nie ma dodatkowych schorŹeń, niektōre z nich charakteryzujā siē złoŹonymi chorobami wspōlistniejājnymi.

Figure 6: Histogram pokazuje rozkłād Symptom_score dla normalnych przypadkōw. Najwiēcej przypadkōw ma symptom_score wynoszący 0, ale przypadki sā bardziej rōwnomiernie rozproszone w przedziale od 1 do 7. Sugeruje to, Źe normalne przypadki mogā mieć rōŹny poziom symptomōw, ale głōwnie wyrōŹniajā siē skrajnie niskimi wartoŹciami.

Figure 7: Tutaj widzimy, Źe wiēkszoŹ przypadkōw normalnych ma comorbidity_score bliski zero, choć niektōre przypadki osiagajā wartoŹć 1. Wskazuje to, Źe wiēkszoŹ przypadkōw normalnych nie ma chorōb wspōlistniejających, ale mogā występować łagodne wspōlistniejące schorŹenia.

Figure 8: Na wykresie przedstawiono Źrednie wartoŹci cech binarnych dla przypadkōw zaklasyfikowanych jako anomalie. Sā to cechy, ktōre wskazujā obecnoŹć lub brak pewnych objawōw lub stanōw zdrowotnych. Wysokie Źrednie wartoŹci wskazujā na częstsze występowanie danej cechy wŹród anomalii: NajwyŹsze Źrednie wartoŹci dotyczā cech takich jak current_dmt (obecnie przyjmowana terapia modyfikujāca chorobę), covid19_self_isolation (izolacja w zwiāzku z COVID-19), oraz covid19_has_symptoms (obecnoŹć symptomōw COVID-19). Oznacza to, Źe osoby klasyfikowane jako anomalie często sā poddane leczeniu, majā objawy lub byli w izolacji. Kolejne wysokie cechy to np. covid19_confirm_case (potwierdzony przypadek) oraz covid19_admission_hospital (przyjęcie do szpitala), co sugeruje, Źe model poprawnie rozpoznał przypadki przyjęć do szpitala jako te najcięższe dodatkowo anomalie mogā byē powiāzane z powaŹnymi objawami chorobowymi takimi jak krōtki oddech.

Figure 9: Na tym wykresie poziomym przedstawiono Źrednie wartoŹci dla rōŹnych cech binarnych w normalnych przypadkach (bez anomalii). Cecha o najwyŹszej Źredniej wartoŹci to current_dmt, co wskazuje, Źe pacjenci normalni często uŹywajā terapii modyfikujācych chorobę (DMT). Inne często występujāce cechy to current_or_former_smoker oraz covid19_self_isolation, oraz covid19_has_symptoms, co sugeruje, Źe objawy COVID-19 i byli bādŹ obecni palacze t znaczna grupa osōb w normalnej grupie.

Figure 10: WiēkszoŹ anomalii dotyczy osōb młodszych (kategoria 1), co moŹe sugerować, Źe młodsze osoby majā wiēksze ryzyko występowania anomalii w danych.

Figure 11: Zdecydowana wiēkszoŹ przypadkōw anomalii dotyczy osōb z niŹszym BMI (kategoria 0), co moŹe wskazywać na zwiāzek miēdzy BMI a nietypowymi przypadkami.

Figure 12: WŹród anomalii przewaŹajā kobiety (kategoria 1), co sugeruje, Źe w danych kobiet częściej występujā anomalie.

Figure 13: WiēkszoŹ anomalii dotyczy osōb bez przypisania do ms_type2 (kategoria 0), ale niektōre przypadki naleŹā do kategorii 1 lub 2.

Figure 14: Rozkłād wskazuje, Źe wŹród anomalii dominujā łagodniejsze wyniki COVID-19 (kategoria 0), choć sā teŹ przypadki umiarkowane (kategoria 1) i cięŹkie (kategoria 2).

7. Podsumowanie

Zgromadzony zbiōr danych liczył jedynie ponad 1100 przypadkōw, co w kontekŹcie analiz statystycznych i uczenia maszynowego jest liczbā stosunkowo niewielkā, szczegōlnie przy analizie złoŹonych zjawisk, takich jak przebieg COVID-19 w okreŹlonych populacjach. Dodatkowo dane te charakteryzowały siē duŹā iloŹciā brakujācych wartoŹci – aŹ okołō 70% przypadkōw zawierało znaczne luki w informacjach, co ograniczało ich uŹytecznoŹć. Tylko 2% przypadkōw dotyczyło osōb hospitalizowanych, co dodatkowo zmniejszało wartoŹć predykcijnā modelu, poniewaŹ cięŹkie przypadki stanowiły bardzo niewielkā częŹć danych i byli słabo reprezentowane.

Problemem była rōwnieŹ nierōwnomiernoŹć rozkłādu danych w kluczowych grupach, takich jak płeć i wiek, co prowadziło do stronniczoŹci wyników. Na przykłād, nierōwnomierna liczba kobiet i męŹczyzn w próbie lub rōŹnice w liczbie obserwacji pomiēdzy grupami wiekowymi powodowały, Źe model mōgł błędnie wyciagāć wnioski na podstawie nadreprezentowanych cech. Brak rōwnowagi w danych utrudniał takŹe identyfikacjē rzeczywistych wzorcōw w populacji i prowadził do fałszywego postrzegania wiarygodnoŹci wyników.

Dodatkowym wyzwaniem w analizie takich danych jest specyfika COVID-19 jako choroby o niejasnych i zrōŹnicowanych objawach klinicznych. COVID-19 moŹe manifestować siē w bardzo szerokim spektrum od całkowicie bezobjawowego przebiegu, poprzez łagodne symptomy, aŹ po cięŹkie przypadki wymagajāce hospitalizacji i intensywnej terapii. Ta zmiennoŹć znacząco utrudnia stworzenie jednolitych wzorcōw klasyfikacyjnych, szczegōlnie gdy dane sā ograniczone i niekompletne. W przypadku omawianego zbioru brak dostatecznej reprezentacji cięŹkich przypadkōw oraz brak dokłādnych informacji o objawach dodatkowo ograniczał moŹliwoŹć identyfikacji kluczowych cech rōŹnicujācych normalne przypadki od anomalii.

W tych okolicznoŹciach zastosowanie modelu one-class SVM nie było włāściwym podejŹciem. Model ten zakłāda, Źe dostępane dane normalne sā wystarczajāco reprezentatywne, by umoŹliwić wykrycie anomalii. JednakŹe w tym przypadku, z powodu małej liczby przypadkōw, braku wystarczajācych przykłādów rzeczywistych anomalii (np. cięŹkich przypadkōw COVID-19), a takŹe brakōw danych i ich nierōwnomiernego rozkłādu, model nie był w stanie skutecznie odrōŹnić anomalii od danych normalnych. W konsekwencji one-class SVM wykazał fałszywie wyniki.

Podsumowujāc, niedostateczna liczba przypadkōw, liczne braki danych, nierōwnomiernoŹć ich rozkłādu oraz brak reprezentatywnoŹci cięŹkich przypadkōw sprawiły, Źe analiza oparta na one-class SVM nie była miarodajna. Wyniki uzyskane przez model byli w duŹej mierze fałszywie pozytywne i nie miały praktycznego znaczenia.

Aby przeprowadzić skuteczniejszā analizę, konieczne byłoby zgromadzenie wiēkszej, bardziej zrōwnoważonej i kompletnej próby danych, uwzględniającej wiēkszā liczbę przypadków klinicznych i cięŜkich przypadków COVID-19.

8. Bibliografia

- [1] Diag.pl. (n.d.). Jakie sā pierwsze objawy i sposoby leczenia stwardnienia rozsianego. Diag.pl. <https://diag.pl/pacjent/artykuly/jakie-sa-pierwsze-ob-jawy-i-sposoby-leczenia-stwardnienia-rozsianego/>
- [2] Medcover. (n.d.). Stwardnienie rozsiane – objawy, przyczyny i leczenie. Medcover. <https://www.medcover.pl/ozdrowiu/stwardnienie-rozsiane-objawy-przyczyny-i-leczenie-6619,n,192>
- [3] Calabresi PA. Diagnosis and management of multiple sclerosis. Am Fam Physician. 2004 Nov
- [4] Montgomery S, Hillert J, Bahmanyar S. Hospital admission due to infections in multiple sclerosis patients. Eur J Neurol. 2013 Aug
- [5] Wikipedia. (2025). Stwardnienie rozsiane. Wikipedia. https://pl.wikipedia.org/wiki/Stwardnienie_rozsiane
- [6] Polskie Towarzystwo Stwardnienia Rozsianego. (2020). COVID-19 a SM. PTSR. <https://ptsr.org.pl/strona/133,covid-19-a-sm>
- [7] Sormani MP, De Rossi N, Schiavetti I, Carmisciano L, Cordioli C, Radaelli M, et al. Disease modifying therapies and COVID-19 severity in multiple sclerosis. Ann Neurol. 2021 Apr
- [8] Louapre C, Collongues N, Stankoff B, Giannesini C, Papeix C, Bensa C, et al. Clinical characteristics and outcomes in patients with coronavirus disease 2019 and multiple sclerosis. JAMA Neurol. 2020 Sep
- [9] Simpson-Yap S, De Brouwer E, Kalincik T, Rijke N, Hillert JA, Walton C, et al. Associations of Disease-Modifying Therapies With COVID-19 Severity in Multiple Sclerosis. Neurology. 2021 Nov
- [10] Schiff MA, Rae-Grant A, Gilden D, Franklin GM. Practice guideline: Disease-modifying therapies for adults with multiple sclerosis: Report of the guideline development, dissemination, and implementation subcommittee of the American Academy of Neurology. Neurology. 2019 Jan
- [11] Erfani P, Mitchell AJ, Hameed S, Heydarpour P, Ghaffaripour R, Sahraian MA. Systematic review of health-related quality of life in multiple sclerosis patients: The impact of pharmacological treatments and lifestyle. J Neurol Sci. 2016 Dec
- [12] Peeters LM, Parciak T, Walton C, Geys L, Moreau Y, De Brouwer E, et al. COVID-19 in people with multiple sclerosis: A global data sharing initiative. Mult Scler Houndmills Basingstoke Engl. 2020 Sep
- [13] Simpson-Yap S, De Brouwer E, Kalincik T, Rijke N, Hillert JA, Walton C, et al. Associations of Disease-Modifying Therapies With COVID-19 Severity in Multiple Sclerosis. Neurology. 2021 Nov
- [14] Physionet. (2025). Patient-level data for COVID and MS. Physionet. <https://physionet.org/content/patient-level-data-co-vid-ms/1.0.1/>
- [15] GeeksforGeeks. (2025). Understanding One-Class Support Vector Machines. GeeksforGeeks. <https://www.geeksforgeeks.org/understanding-one-class-support-vector-machines/>
- [16] Scikit-learn. (2025). OneClassSVM. Scikit-learn. <https://scikit-learn.org/dev/modules/generated/sk-learn.svm.OneClassSVM.html>
- [17] Baeldung. (2025). One-Class SVM. Baeldung. <https://www.baeldung.com/cs/one-class-svm>
- [18] Medium. (2025). Anomaly detection using support vectors. Medium. <https://medium.com/@roshmitadey/anomaly-detect-ion-using-support-vectors-2c1b842213ed>
- [19] Anna Mrozek, Bartosz Panek, Przemysław Jura. (2025). Analiza zbioru pacjētōw z SM chorych na COVID-19 modelem One-Class SVM. <https://github.com/przemyslaw-Jura00/RozpoznawanieWzorcowGrupa4>




Figure 3: Wykryte anomalie vs Normalne próbki: -1: anomalia
1: normalny przypadek

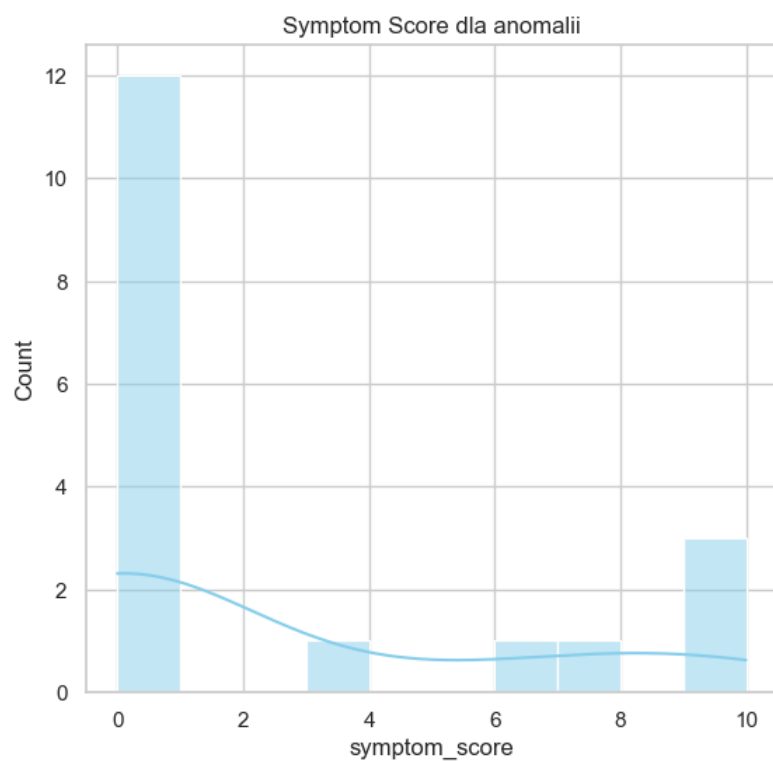


Figure 4: Rozkład ilości symptomów dla anomalii




Figure 5: Rozkład ilości chorób współistniejących dla anomalii




Figure 6: Rozkład ilości symptomów dla przypadków normalnych




Figure 7: Rozkład ilości chorób współistniejących dla przypadków normalnych




Figure 8: Średnie wartości charakterystycznych cech dla anomalii




Figure 9: Średnie wartości charakterystycznych cech dla przypadków normalnych




Figure 10: Rozkład wieku wśród anomalii: 0: jeśli zakres wieku mieści się w przedziale od 0 do <18. 1: jeżeli przedział wiekowy mieści się w przedziale od 18 do <=50 lat. 2: jeżeli przedział wiekowy mieści się w przedziale od 51 do <=70 lat. 3: jeśli przedział wiekowy wynosi 71 lat lub więcej..




Figure 11: Rozkład bmi wśród anomalii: 0: not _overweight: if BMI ≤ 30 kg/m² 1: overweight: if BMI > 30 kg/m².

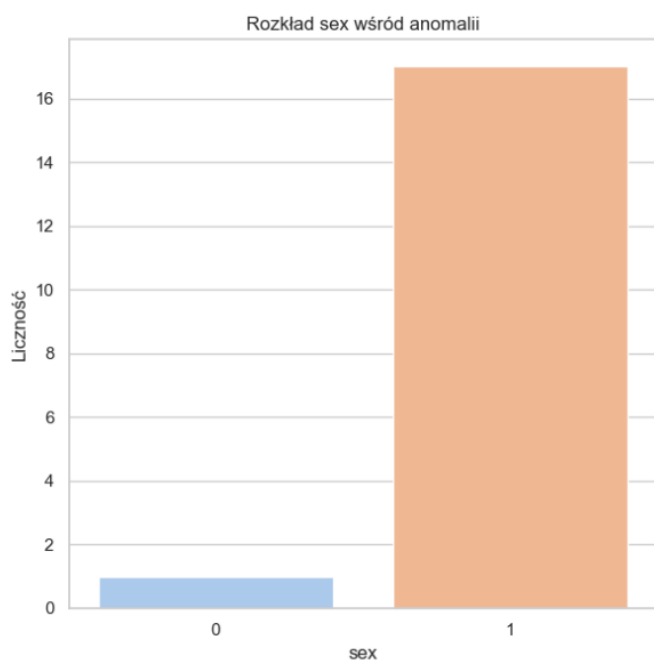


Figure 12: Rozkład płci wśród anomalii: 0: mężczyźni 1: kobiety

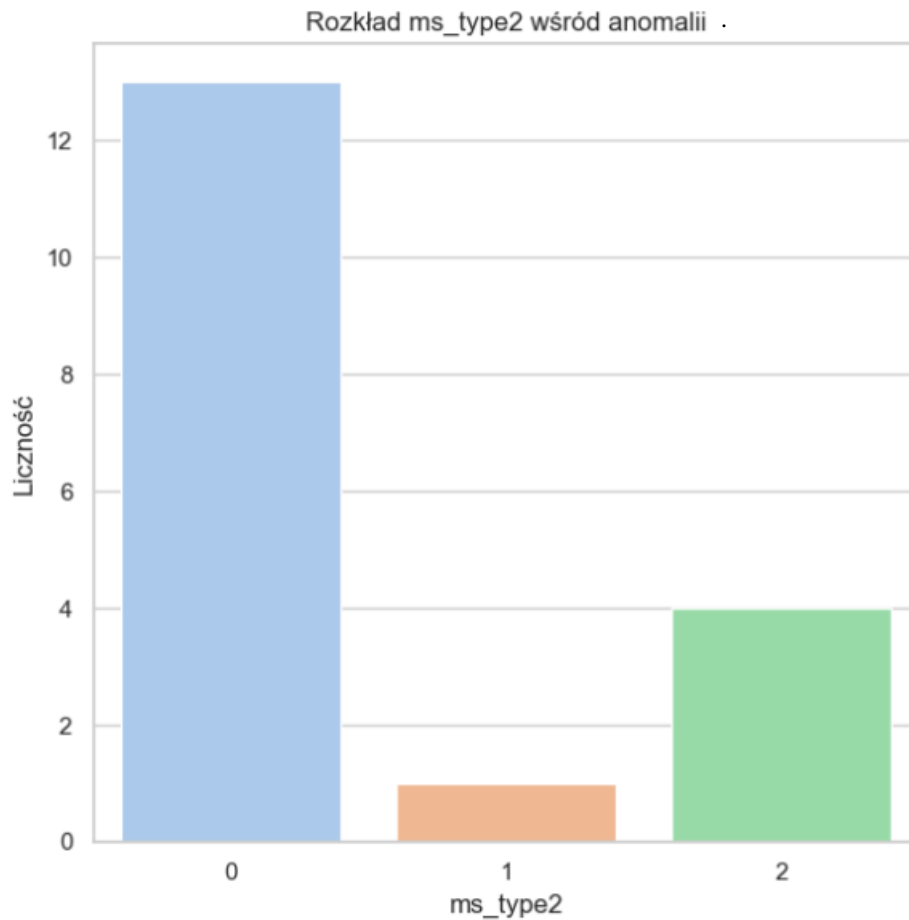


Figure 13: Rozkład typu stwardnienia rozsianego wśród anomalii: 0: relapsing_remitting: jeśli typ stwardnienia rozsianego to stwardnienie rozsiane rzutowo-remisyjne (RRMS) 1: progresywny_MS: jeśli typ stwardnienia rozsianego to wtórnie postępujące stwardnienie rozsiane (SPMS) lub pierwotnie postępujące stwardnienie rozsiane (PPMS) 2: inny: jeśli typ stwardnienia rozsianego to zespół izolowany klinicznie (CIS) lub pusty lub „niepewny”, w przypadku gdy pacjent lub lekarz nie był pewien.




Figure 14: Rozkład hospitalizowanych przypadkōw: 0: Jeśli dana osoba ma Covid-19, ale nie była hospitalizowana. 1: Osoba ma Covid-19 i została hospitalizowana. 2: Osoba ma Covid-19, była hospitalizowana, przebywała na oddziale intensywnej terapii i/lub przebywała w ośrodku wentylacyjnym. 3: Osoba zmarła z powodu Covid-19 (nieobecna w tym zbiorze danych).